



Classificação de Notícias



Carlos Eduardo B S Araujo
17 Julho 2026



Objetivo



Desenvolver uma solução de Inteligência Artificial capaz de classificar automaticamente notícias jornalísticas em suas respectivas categorias, utilizando como base os dados disponibilizados para treinamento.


Entrada (notícias):

- Título
- Texto
- Subcategoria

Saída:


- Categoria





Arquitetura da Solução






Análise Exploratória de Dados

Principais Descobertas:




- Base composta por notícias em português.
- Grande quantidade de categorias, com distribuição desbalanceada.
- Presença de campos ausentes, principalmente texto e subcategoria.
- Existência de registros duplicados e categorias inconsistentes.
- Presença de ruídos, como HTML, URLs, espaços extras e caracteres desnecessários.


Impactos da EDA



Descoberta	Decisão tomada
Ruídos textuais	Construção de pipeline de limpeza
Texto ausente	Manter registros quando outras informações eram suficientes
Categorias pequenas	Removidas apenas no treinamento
Subcategoria ausente e muitas opções	Mantidas como feature adicional
Dados inconsistentes	Normalização das categorias e subcategorias
Registros duplicados (mesmo título e texto)	Manutenção de apenas um registro, eliminando duplicatas exatas
Registros com mesmo título e texto, mas categorias diferentes	Remoção da base de treinamento para evitar informações conflitantes e reduzir o impacto negativo no aprendizado do modelo



Pré-processamento e Engenharia de Features



1. Lematização (spaCy)

- Remoção de stopwords e pontuação.
- Conversão das palavras para seu lema.
- Cache do dataset lematizado para evitar reproprocessamento.

Exemplo: "O jogadores estavam correndo rapidamente." → "jogador correr rapidamente"


2. Engenharia de Features

Campo	Transformação
Título	TF-IDF (peso 2.0)
Texto	TF-IDF (peso 1.0)
Subcategoria	One-Hot Encoding (peso 0.5)

As features são combinadas através do **ColumnTransformer**, permitindo atribuir diferentes importâncias a cada informação.



Construção do Modelo




Treinamento

- Remoção de categorias com menos de 800 exemplos.
- Divisão da base em 90% treinamento e 10% teste.
- Treinamento utilizando Regressão Logística.
- Balanceamento automático das classes.

Validação

Métricas utilizadas:

- **Acurácia** → percentual de classificações corretas.
- **F1-Score Macro** → avalia igualmente todas as categorias.
- **F1-Score Weighted** → pondera o desempenho conforme a quantidade de exemplos por categoria.



Resultados Gerais



91,25%

Acurácia


91,44%

F1-Score (Weighted)

82,61%

F1-Score (Macro)

O modelo apresentou alta capacidade de classificação em um problema com 22 categorias, obtendo mais de 91% de acerto.



Resultados Por Categorias




Categorias com menor desempenho

Colunas	Esporte
Poder	Mundo

Principais causas

- Alto volume de exemplos.
- Vocabulário específico e bem definido.
- F1-Score superior a 0,90 na maioria das categorias.



Resultados Por Categorias



Categorias com menor desempenho

BBC

Ilustríssima

Comida

Equilíbrio e Saúde

Principais causas

- Menor quantidade de exemplos para treinamento.
- Sobreposição temática entre categorias semelhantes.
- Maior dificuldade para aprender padrões exclusivos.

API – Produtização

A solução foi disponibilizada por meio de uma API REST, permitindo que o modelo seja consumido por aplicações externas de forma simples e padronizada.

Endpoints

POST /predict

Classificação de uma única notícia.

- Entrada: título, texto e subcategoria.
- Saída: categoria prevista pelo modelo.

POST /predict/batch

Classificação de múltiplas notícias em uma única requisição.

- Processamento em lote.
- Retorno das categorias previstas para cada registro.

